



Y'TILIKAN

AfriBench

Évaluer les LLM sur les réalités africaines

Benchmark public, ouvert, reproductible et contextuellement ancré

Christian Nebot · Y'TILIKAN Demo Day · Édition 1

Les benchmarks LLM ignorent l'Afrique

MMLU, HellaSwag, HumanEval sont anglo-centrés et occidentalo-centrés.

Langues

Aucune langue africaine évaluée dans les benchmarks de référence.

Thématiques

Histoire, droit, économie, santé et culture du continent sous-représentés.

Conséquence

On ne peut pas mesurer comment les modèles se comportent sur nos réalités.

Un benchmark africain, ouvert et reproductible

- Corpus de questions validées, couvrant 9 catégories de connaissances africaines.
- Pipeline d'évaluation automatisé, reproductible et documenté.
- Leaderboard public pour suivre l'évolution des modèles.

Porté par Y'TILIKAN : focus sur les problèmes africains, compétences réelles.

101

questions validées

9

catégories

8

modèles configurés

1

langue (fr) pour l'instant

Les 9 catégories

Histoire · Géographie · Droit et Politique · Santé et Sciences · Langue et Culture · Économie · IA et Technologie · Société ·
Raisonnement Culturel

data/questions

Corpus QCM : template + v1 (raw / validated)

scripts

afribench.py (CLI d'évaluation) · export_frontend.py

configs

models.yaml (8 modèles) · categories.yaml (9 catégories)

frontend

Application web statique : leaderboard, filtres, catégories

Frameworks

Déployé : afribench.vercel.app · Code : github.com/YTILIKAN/AfriBench

Prototype v0.1 : on assume les limites

- 101 questions** échantillon trop petit pour classer les modèles de façon statistiquement significative.
- Français uniquement** aucune langue africaine encore évaluée.
- Validation externe absente** corpus rédigé par une seule personne, validateurs en cours de recrutement.
- QCM exclusif** pas encore de tâches ouvertes (génération, traduction, raisonnement).

Phase 1 Corrections critiques : accessibilité, XSS, contraste, wording.

Phase 2 300-350 questions, 20 témoins, 3 validateurs africains.

Phase 3 2-3 langues africaines, tâches ouvertes, soumission académique.

Un benchmark de référence, ancré dans les réalités africaines.