



Y'TILIKAN

AfriBench

Rapport technique

Évaluer les modèles de langage sur les réalités africaines

Prototype v0.1 · Juin à septembre 2026

Christian Nebot · Chargé des projets

LE PROBLÈME

Les benchmarks LLM de référence (MMLU, HellaSwag, HumanEval) sont massivement anglo-centrés et occidentalo-centrés. L'Afrique y est sous-représentée, dans les langues comme dans les thématiques : histoire, droit, économie, santé, culture du continent.

LA SOLUTION

AfriBench est un benchmark public, ouvert et reproductible qui mesure la performance des modèles de langage sur des connaissances africaines, à travers un corpus contributif de questions validées et un tableau de bord public pour suivre l'évolution des modèles.

OBJECTIFS

- Mesurer la performance des LLMs sur des connaissances africaines (9 catégories thématiques).
- Constituer un corpus ouvert et contributif de questions validées.
- Fournir un leaderboard public reproductible et documenté.

STRUCTURE DU DÉPÔT

data/questions/	Corpus de questions (template + v1 raw/validated)
scripts/	Pipeline d'évaluation (afribench.py, export_frontend.py)
configs/	Modèles évalués (8) et catégories (9)
frontend/	Application web statique (leaderboard, catégories)
research/	Cadrage : finalité, objectifs, phases, stack, livrables

LES 9 CATÉGORIES

Histoire · Géographie · Droit et Politique · Santé et Sciences · Langue et Culture · Économie · IA et Technologie · Société · Raisonnement Culturel

MODÈLES ÉVALUÉS

GPT-4o · GPT-4o Mini · Claude Sonnet 4 · Claude 3.5 Haiku · Mistral Large · Gemini 2.0 Flash · DeepSeek V4 · Llama 3.1 70B

FRAMEWORKS RETENUS

LM Evaluation Harness (benchmark principal), OpenCompass (multilingue), Promptfoo (CI), DeepEval (industrialisation), HELM (cadre méthodologique).

LIMITES CONNUES (HONNÊTÉTÉ)

101 questions	~11 par catégorie, insuffisant statistiquement. Cible : 300+.
Français uniquement	aucune langue africaine évaluée. Planifié : swahili, yoruba, amharique.
Validation externe absente	corpus rédigé par une seule personne. Recrutement de 3 validateurs.
Format QCM exclusif	pas de génération/traduction. Tâches ouvertes planifiées.

ROADMAP

- Phase 1** Corrections critiques : accessibilité, XSS, contraste, wording.
- Phase 2** 300-350 questions, 20 témoins, 3 validateurs, protocole documenté.
- Phase 3** Traduction en 2-3 langues africaines, tâches non-QCM, LM Eval Harness, soumission académique.
- Phase 4** Frontend long-terme : HTML pré-généré, structured data, tests.

Liens

GitHub : github.com/YTILIKAN/AfriBench · App : afribench.vercel.app